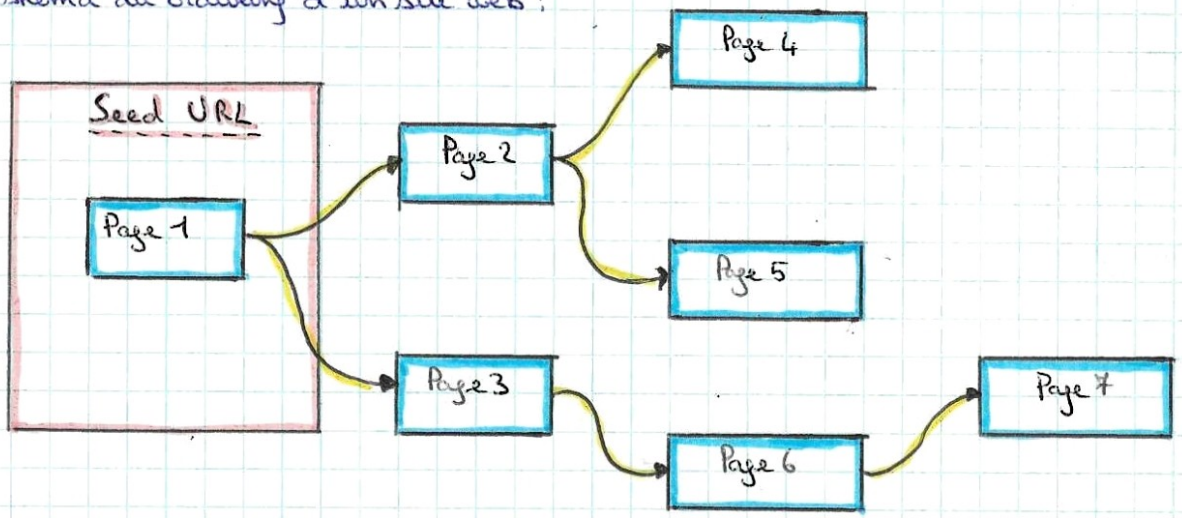
notre robot peux permettre une super cartographie de l'application web, ci dessous schéma du crawling d'un site web :



Le fichier robots.txt: c'est un fichier placé à la racine du serveur qui respet le protocole d'exclusion des robots, il se base sur le useragent pour exclure autorisé explicitement ou fixer certaines règles d'exploration à un ou plusieurs bots il est utile pour nous car il peux nous permettre de reperer des repertoires intéressant naturellement les bots malveillant n'en tiennent pas compte

Example :

```
User-agent : *
Disallow   /private/
Allow      /public
```

Les directives du robots.txt :

- Disallow : Spécifie chemin ou motif que le bot ne doit pas explorer
- Allow : Autorise explicitement le bot à explorer des chemins ou motifs spécifiques, même si ils relèvent d'un Disallow plus large.
- Crawl-delay : Definit un délai en secondes entre les requêtes successives du bot pour éviter la surcharge du serveur
- Sitemap : fournit l'url d'un site XML pour une exploitation plus efficace

L'URI. Well-Know : la norme well-Know (definie dans RFC 8615) sert de repertoir standarisé au sein du domain racine d'un site-web accessible via /.well-know sur un site web elle centralise les métadonnée d'un site web, y compris fichiers de configuration, informations relatives aux services protocoles et mécanisme de sécurité, ca simplifie le processus d'accès aux navigateurs web.

-/.well-know/security.txt : Contient des informations de contact pour que les chercheurs en cybersécurité puissent signaler des activités.

-/.well-know/change-password : fournit une url standart pour rediriger les utilisateurs vers une page de changement de mot de passe.

-/.well-know/openid-configuration définit les details de configuration pour open ID connect une couche d'identité au dessus du protocole Oauth 2.0 - (ces protocoles de sécurité permettent à deux sites différents d'échanger des informations sur nous de manière sécurisée - Ex - bouton se connecter avec google facebook github. etc...)

-/.well-know/assetslink.json sert à prouver la propriété d'actifs numériques associés à un domain - Ex application Android et site web

-/.well-know/mta-sts.txt Spécifie la politique pour SMTP MTA Strict-Transport-Security, afin d'améliorer la sécurité de la messagerie électronique.

Il existe bien d'autres endpoints de well-Know mais voici les principaux!
Plusieurs outils et ressources sont interessantes pour le crawling sitons en quelques uns ;
Burp Suite Spider, OWASP ZAP (Zed Attack Proxy), Scrapy (framework python)
Apache Nutch (bien pour du grande échelle).
N'oublions pas de respecter les règles éthiques quelque soit l'outil.